TRABAJO FIN DE MÁSTER

Máster en Big Data, Data Science e Inteligencia Artificial

Scoring de comportamiento con scorecard interpretable: equidad, pérdida esperada IFRS 9, recobro y puesta en producción.

Aplicación al dataset *Default of Credit Card Clients*



Autor

Pablo Blas Hernández

Curso académico 2025/2026

Índice

1. Introducción 4
1.1. Motivación y contexto 4
1.2. Objetivos 4
1.3. Alcance y limitaciones 4
2. Marco teórico y regulatorio 5
2.1. Componentes del riesgo de crédito 5
2.2. Basilea III e IFRS 9 5
2.3. Scorecard, WOE e Information Value 5
2.4. Equidad algorítmica y variables protegidas 5
3. Dataset y diseño de la base de datos 6
3.1. Dataset Default of Credit Card Clients 6
3.2. Derechos de uso 6
3.3. Protección de datos (RGPD) 6
3.4. Representatividad y actualidad 6
3.5. Diseño relacional en SQLite 6
4. Análisis exploratorio (EDA) 7
4.1. Variable objetivo 7
4.2. Variables categóricas 7
4.3. Variables continuas 8
5. Análisis de equidad (fairness) y variables protegidas 8
5.1. Metodología 8
5.2. Resultados y decisión 8
5.3. Estabilidad del veredicto 8
5.4. Medición del riesgo de discriminación indirecta (proxy) 9
6. Modelización: construcción del scorecard 9
6.1. División train/test 9
6.2. Variables derivadas 9
6.3. Tramificación óptima con optbinning 10
6.4. Regresión logística y selección de variables 10
7. Validación del modelo 12
7.1. Diagnóstico dentro y fuera de muestra 12
7.2. Validación cruzada estratificada 12
7.3. Calibración y estabilidad 12
7.4. Validación desplazada en el tiempo 13
7.5. Punto de corte sensible al coste 13

8. Modelo challenger: XGBoost, SHAP y MLflow 14
8.1. Trazabilidad con MLflow 14
8.2. Comparativa y explicabilidad 15
9. Aplicación práctica e IFRS 9 16
10. Modelo de recobro 17
10.1. Diseño y validación 17
10.2. Estrategias de recobro 17
10.3. Alcance 18
11. Puesta en producción: API REST con FastAPI y Docker 18
11.1. Endpoints y validación 18
11.2. Contenerización 19
12. Integración operativa: agentes conversacionales 19
12.1. Canal al titular: pre-evaluación orientativa 19
12.2. Canal al gestor: asistente de cartera 20
12.3. Trazabilidad en todas las capas 21
13. Visualización ejecutiva en Tableau 22
13.1. Vistas del dashboard 22
14. Conclusiones y líneas futuras 23
14.1. Conclusiones 23
14.2. Líneas futuras 23
Bibliografía 24
Anexos 25

1. Introducción

1.1. Motivación y contexto

El riesgo de crédito es una de las funciones más críticas de la gestión bancaria. En el segmento de tarjetas de crédito, las entidades no solo deben decidir a quién conceder una tarjeta (*scoring* de admisión), sino monitorizar de forma continua el comportamiento de pago de los titulares que ya la tienen, anticipando qué clientes entrarán en mora. Este segundo enfoque, conocido como *scoring* de comportamiento, es el que aborda este trabajo, y es especialmente relevante para el cálculo de provisiones bajo IFRS 9 (NIIF 9).

El dataset elegido, "Default of Credit Card Clients", recoge seis meses de historial de pagos, facturación y amortización de 30.000 titulares de un banco taiwanés, junto con la variable objetivo de si entraron o no en mora el mes siguiente. La elección responde a una restricción del dominio: los datos de riesgo de crédito rara vez son públicos, y el *scoring* de comportamiento exige el historial de pagos de cada titular durante varios meses. Es uno de los pocos conjuntos accesibles con origen real en una entidad bancaria y seis meses de comportamiento observado. Sobre este mismo conjunto existen trabajos de investigación que aplican métodos de equidad y explicabilidad (Valdrighi et al., 2025); este trabajo se distingue por el enfoque regulatorio: un *scorecard* interpretable, la pérdida esperada bajo IFRS 9 y su integración operativa.

1.2. Objetivos

Objetivo general: Desarrollar un sistema de *scoring* de comportamiento de extremo a extremo que estime la probabilidad de impago de un titular de tarjeta y lo integre en un flujo operativo con base de datos, modelo de recobros, API, agentes conversacionales y visualización, cumpliendo el marco regulatorio (Basilea III, IFRS 9) y los principios de equidad algorítmica.

Objetivos específicos:

- Construir un *scorecard* de regresión logística con tramificación WOE, que incorpore variables derivadas del comportamiento de pago y coeficientes con el signo esperado.
- Realizar un análisis de equidad sobre la variable protegida sexo y justificar su exclusión.
- Contrastar el *scorecard* con un XGBoost explicado con SHAP y trazado con MLflow.
- Fijar el punto de corte con criterio de coste y calcular la pérdida esperada IFRS 9 con PD a 12 meses y a toda la vida.
- Productivizar el modelo como API REST con FastAPI y Docker, e integrarlo en dos agentes conversacionales y un dashboard en Tableau.
- Construir un modelo de recobro que, para los titulares ya en mora, estime la probabilidad de que no se recuperen el mes siguiente y la traduzca en estrategias de gestión.

1.3. Alcance y limitaciones

El trabajo se centra en el *scoring* de comportamiento sobre una cartera existente. El dataset no incluye fechas reales, de modo que la validación temporal se aproxima desplazando la ventana dentro de los seis meses de historial (capítulo 7). La LGD se fija en un valor convencional del 45 % al no disponer de datos de recuperación, y el factor de conversión del crédito se estima con una muestra reducida. El modelo de recobro cubre solo la mora de 60 días y un horizonte de un mes, y sus estrategias son una propuesta no contrastada con un experimento (capítulo 10).

La reproducibilidad se trata como requisito de diseño y no como consecuencia: la base de datos es un fichero portable, los parámetros de riesgo residen en un único módulo compartido, el entrenamiento de ambos modelos tiene semilla fijada y queda trazado en MLflow, y el servicio se distribuye contenerizado.

2. Marco teórico y regulatorio

2.1. Componentes del riesgo de crédito

La pérdida esperada (ECL en la IFRS 9) se descompone en tres componentes: la probabilidad de *default* (PD), que estima el modelo; la *Loss Given Default* (LGD), porcentaje de la exposición que se pierde tras el *default*; y la *Exposure at Default* (EAD). En una tarjeta, la exposición no es solo el saldo dispuesto: el titular puede seguir disponiendo de su límite libre hasta entrar en *default*, lo que se recoge con un factor de conversión del crédito (CCF), que se estima con los datos en el capítulo 9. Para la LGD se adopta un valor convencional del 45 %, ante la ausencia de datos de recuperación. La LGD de IFRS 9 es una estimación propia de la entidad; como referencia prudencial, el suelo de LGD para exposiciones renovables minoristas sin garantía en el cálculo de capital IRB es del 50 % (art. 164 CRR), por lo que la sensibilidad del capítulo 9 incluye ese valor.

$$ECL = PD \times LGD \times EAD$$

2.2. Basilea III e IFRS 9

Basilea III mantiene el enfoque IRB (Basel Committee on Banking Supervision, 2017), que permite a las entidades estimar internamente la PD. El artículo 178 del CRR (Reglamento (UE) 575/2013) define el *default* por impago superior a 90 días, definición que no coincide con la variable objetivo del *scorecard* (impago en el mes siguiente): su PD es de comportamiento, y para la provisión se construye además una PD de *default* a 90 días (capítulo 9).

La IFRS 9 (IFRS Foundation, 2014), de aplicación desde 2018, sustituye la pérdida incurrida por la esperada (ECL) y clasifica cada operación en tres *stages*, que determinan si la provisión se calcula a 12 meses (Stage 1) o a toda la vida de la operación (Stages 2 y 3). La norma establece dos presunciones basadas en el retraso: más de 30 días indica un aumento significativo del riesgo (Stage 2) y 90 días o más, deterioro (Stage 3).

2.3. Scorecard, WOE e Information Value

Un *scorecard* (Siddiqi, 2017) transforma cada variable mediante el *Weight of Evidence* (logaritmo del cociente entre la proporción de buenos y malos pagadores del total que caen en cada tramo) y ajusta una regresión logística sobre esas transformaciones. El *Information Value* (IV) mide el poder predictivo de cada variable y sirve como criterio de selección (se descartan las de IV inferior a 0,02). Con esta convención, un WOE mayor indica menos riesgo, de modo que todos los coeficientes del modelo deben ser negativos. El resultado se calibra a una escala de puntuación mediante el método PDO/*odds* (Materiales docentes del máster, 2025/2026).

Además de ordenar a los clientes, el modelo debe estar calibrado: una PD del 20 % debe corresponder a una frecuencia de impago próxima al 20 %. La calibración es la que permite usar la probabilidad para provisionar y para fijar el punto de corte por coste, comparando lo que cuesta dejar pasar un impago con lo que cuesta revisar a un buen pagador (Elkan, 2001).

2.4. Equidad algorítmica y variables protegidas

Los modelos de *credit scoring* están sujetos a requisitos de no discriminación. La Directiva 2004/113/CE establece el principio de igualdad de trato entre hombres y mujeres en el acceso a bienes y servicios. La equidad algorítmica proporciona métricas para evaluar si un modelo trata de forma desigual a distintos grupos, siendo el *Disparate Impact* (cociente entre las tasas de resultado favorable de dos grupos, con umbral de la regla del 80 %) una de las más utilizadas (Barocas, Hardt & Narayanan, 2019). Este trabajo aplica este análisis a la variable sexo.

3. Dataset y diseño de la base de datos

3.1. Dataset Default of Credit Card Clients

El dataset, publicado en el UCI Machine Learning Repository, contiene 30.000 registros de titulares de tarjeta de un banco taiwanés observados entre abril y septiembre de 2005. Cada registro incluye límite de crédito, variables demográficas (sexo, nivel educativo, estado civil y edad), el historial de estado de pago de los últimos seis meses (PAY_1 a PAY_6), los importes facturados (BILL_AMT1 a BILL_AMT6) y los importes pagados (PAY_AMT1 a PAY_AMT6). La variable objetivo indica si el cliente entró en mora el mes siguiente.

Durante la preparación se agrupan las categorías no documentadas de EDUCATION (valores 0, 5 y 6 se asignan a la categoría 4, "otros") y de MARRIAGE (el valor 0 se asigna a la categoría 3), y se renombra la columna PAY_0 como PAY_1. La verificación de calidad no detecta nulos ni duplicados, pero sí una inconsistencia del propio dataset: la categoría de un mes de retraso aparece 3.688 veces en PAY_1 (septiembre) y prácticamente nunca en los meses anteriores (28, 4, 2, 0 y 0). La columna más reciente se codifica de forma distinta, lo que es coherente dentro del corte pero impide comparar septiembre con los meses previos; por ello, las estimaciones que recorren el historial (capítulos 7, 9 y 10) usan los meses de abril a agosto. El fichero original se aporta en el Anexo 6.

3.2. Derechos de uso

El dataset se distribuye a través del UCI Machine Learning Repository bajo licencia Creative Commons Attribution 4.0 International (CC BY 4.0), que permite expresamente su uso, incluido el académico, con la única condición de citar la fuente. La atribución (Yeh & Lien, 2009; Yeh, 2016) se recoge en la bibliografía.

3.3. Protección de datos (RGPD)

El dataset es de 2005 y no contiene identificadores directos, si bien conserva cuasi-identificadores (edad, sexo, nivel educativo, estado civil e historial de pagos). Se trata por tanto como un conjunto seudonimizado y no anónimo, criterio coherente con el aplicado al registro de consultas del agente conversacional (capítulo 12). Además, como se detalla en el capítulo 5, el modelo excluye la variable sexo por cumplimiento de la Directiva 2004/113/CE.

3.4. Representatividad y actualidad

El dataset corresponde a una entidad taiwanesa en 2005, por lo que sus patrones podrían no trasladarse directamente a otro mercado o época. Es, no obstante, un *benchmark* ampliamente validado que garantiza la comparabilidad con la literatura. En un contexto real, el modelo se entrenaría con datos actuales de la propia entidad y se complementaría con fuentes externas como los burós de crédito.

3.5. Diseño relacional en SQLite

La información se estructura en una base de datos SQLite con un modelo relacional de tres tablas: cliente (datos demográficos), tarjeta_credito (límite y variable objetivo, que admite valor nulo cuando el desenlace todavía no se ha observado) e historial_pagos (los seis meses de estados, facturas y pagos). Una vista v_scoring reconstruye la tabla plana que consume el modelo y la tabla cartera_scoring guarda la cartera puntuada que consulta el agente del gestor. SQLite garantiza la reproducibilidad sin servidor. El esquema y el proceso de carga se recogen en el Anexo 4.

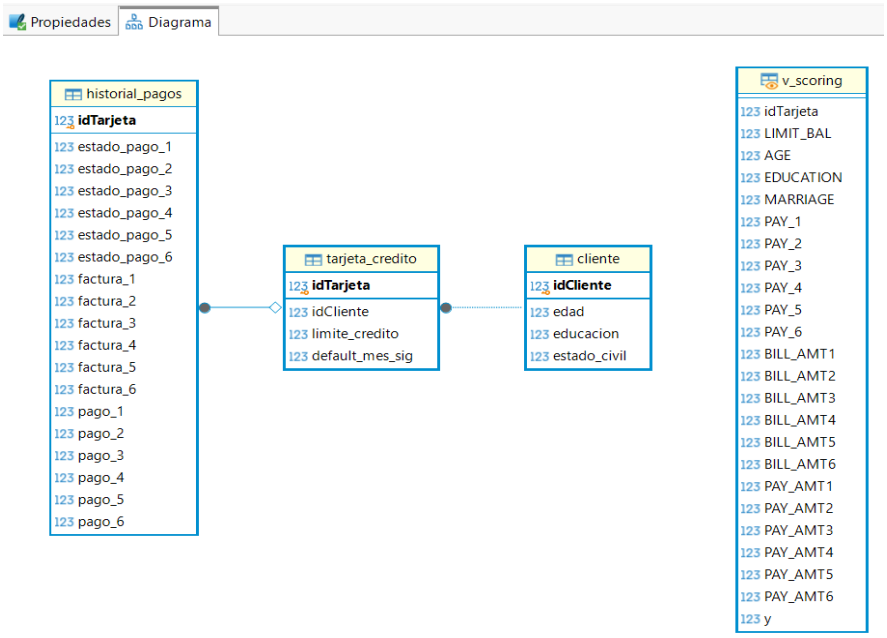


Figura 1. *Modelo de datos relacional en SQLite.*

4. Análisis exploratorio (EDA)

4.1. Variable objetivo

La variable objetivo presenta un 22,1 % de clientes en mora frente a un 77,9 % que atienden sus pagos, un desbalance moderado habitual en carteras de tarjetas que no requiere técnicas de remuestreo, pero sí condiciona la elección del punto de corte y las métricas del modelo: se desaconseja el *accuracy* como métrica principal, al ser poco informativo cuando una clase domina.

4.2. Variables categóricas

Para las variables categóricas (sexo, educación, estado civil y los estados de pago PAY_1 a PAY_6) se aplica el test chi-cuadrado de independencia frente a la variable objetivo. Dado el tamaño muestral, el contraste declara significativas asociaciones de magnitud muy dispar, por lo que la ordenación por capacidad predictiva se apoya en el *Information Value* del capítulo 6 y no en el p-valor. Los estados de pago, y muy especialmente PAY_1 (el más reciente), resultan los predictores más potentes: el retraso en el pago del mes anterior es, con diferencia, la señal más fuerte de mora futura.

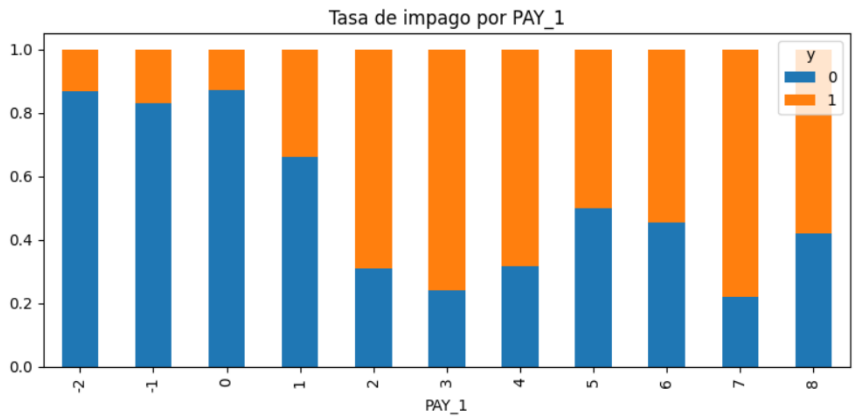


Figura 2. *Tasa de default según el estado de pago más reciente (PAY_1).*

4.3. Variables continuas

Para las variables continuas (límite de crédito, edad, importes de factura y de pago) se emplea el test ANOVA para contrastar la diferencia de medias entre clientes con y sin *default*. Los importes son muy asimétricos, por lo que el resultado es indicativo. El límite de crédito muestra una asociación clara (los clientes con menor límite tienden a mayor mora), mientras que la edad tiene un poder discriminador más limitado. El análisis completo se desarrolla en el Anexo 1.

5. Análisis de equidad (fairness) y variables protegidas

Antes de fijar las variables del modelo se analiza la equidad respecto al sexo, variable protegida por la normativa antidiscriminación. El objetivo es cuantificar el coste predictivo de excluirla y comprobar que el modelo finalmente desplegado no genera un impacto adverso apreciable.

5.1. Metodología

La equidad se mide sobre la *scorecard* real, la misma que consumen la API y los agentes, con el preprocesado, las variables derivadas, la selección de variables y la partición del capítulo 6. Se ajustan dos configuraciones, con y sin la variable sexo, y se comparan con el punto de corte desplegado (capítulo 7), definiendo como resultado favorable no ser marcado en riesgo. Se informan tres métricas: *Disparate Impact* (paridad demográfica, umbral 0,80), brecha de igualdad de oportunidad (ΔTPR) y brecha de falsos positivos (ΔFPR). Las dos primeras no pueden satisfacerse simultáneamente cuando la prevalencia difiere entre grupos, como ocurre aquí (0,243 frente a 0,207), por lo que ninguna cifra aislada basta como certificado de equidad.

5.2. Resultados y decisión

El *Information Value* del sexo es de 0,0088, por debajo del umbral de 0,02: el propio criterio estadístico del *scorecard* lo descarta, de modo que la exclusión exigible por el principio de igualdad de trato coincide con la que habría hecho el modelo. Forzando su entrada para medir el contrafactual, el AUC de test pasa de 0,7594 a 0,7605, una diferencia de 0,0010, muy inferior al intervalo de confianza del propio AUC.

Sobre la *scorecard* desplegada el *Disparate Impact* es de 0,983, con brechas de 0,002 (ΔTPR) y 0,003 (ΔFPR). Incluir el sexo lo reduce a 0,924 y multiplica las brechas por más de diez, a cambio de una ganancia predictiva inapreciable. El punto de corte apenas influye: con el corte neutro el DI del modelo desplegado sería de 0,980, frente al 0,983 con el corte sensible al coste.

Configuración	AUC test	Disparate Impact	Regla 80%	ΔTPR	ΔFPR
Scorecard sin sexo	0,7594	0,983	Cumple	0,002	0,003
Scorecard con sexo	0,7605	0,924	Cumple	0,039	0,038
Rango en 5 particiones	0,759 - 0,780	0,942 - 0,983	5 de 5	0,002 - 0,048	0,001 - 0,026

Tabla 1. *Comparativa del modelo incluyendo y excluyendo la variable sexo.*

5.3. Estabilidad del veredicto

El DI es un cociente entre proporciones estimadas sobre submuestras y arrastra error muestral. Repitiendo el ciclo completo sobre cinco particiones, se mueve entre 0,942 y 0,983 (media 0,962, desviación 0,017), cumpliendo el umbral en las cinco. Se informa el rango y no un valor puntual, porque la equidad no se certifica una vez: se monitoriza por ventanas, igual que la estabilidad del modelo.

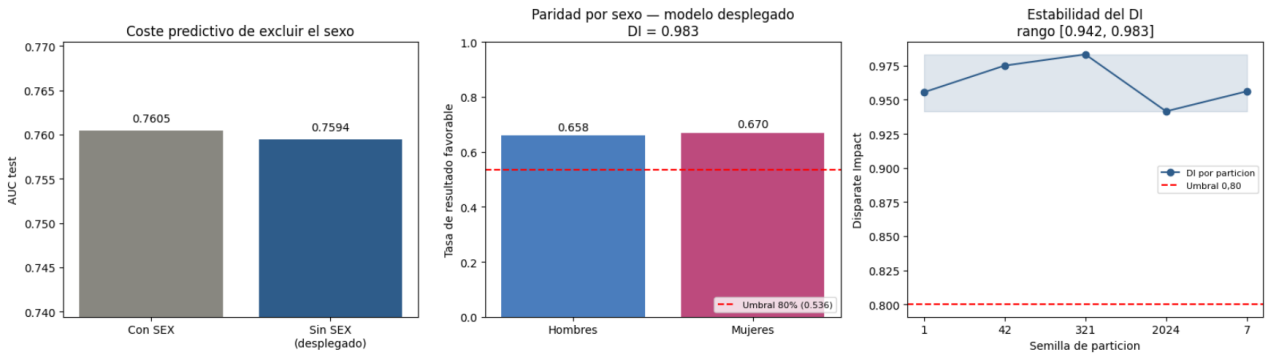


Figura 3. *Impacto de la exclusión de la variable protegida sexo.*

5.4. Medición del riesgo de discriminación indirecta (proxy)

Excluir la variable no elimina el riesgo de que otras la reproduzcan. La correlación máxima con el sexo es de 0,093 (la edad), seguida de la utilización media del límite (0,074), y un modelo auxiliar que intenta predecir el sexo a partir de las variables del modelo desplegado alcanza un AUC de 0,563, que se mantiene entre 0,563 y 0,577 en cinco particiones. Frente al 0,5 que indicaría ausencia de filtración, revela un riesgo proxy leve pero no nulo, que justifica la monitorización continua. En conjunto, el sexo no aporta información útil para anticipar la mora: la entidad puede cumplir el principio de igualdad de trato sin sacrificio comercial, vigilando de forma periódica la pequeña señal residual del resto de variables. El desarrollo íntegro se recoge en el Anexo 3.

6. Modelización: construcción del scorecard

6.1. División train/test

El dataset se divide en un 80% de entrenamiento y un 20% de test mediante muestreo estratificado por la variable objetivo, con semilla fijada. Sobre las variables continuas se aplica una winsorización en los percentiles 1 y 99, con límites calculados únicamente sobre el entrenamiento y aplicados después al test, de modo que ninguna información del test interviene en el ajuste.

6.2. Variables derivadas

A las variables originales se añaden seis variables derivadas que recogen relaciones que aquellas no expresan por separado. Son transformaciones fila a fila sin parámetros estimados, por lo que se calculan antes de la partición sin introducir fuga, y se obtienen sobre valores brutos para que entrenamiento y producción coincidan. En los cocientes, un denominador nulo o negativo deja la variable sin definir: un titular sin factura no tiene un esfuerzo de pago del 0%, sino ninguno, y la tramificación envía esos casos a su propio tramo.

Variable	Fórmula	Qué mide	IV
util_limite	BILL_AMT1 / LIMIT_BAL	Parte del límite dispuesta	0,072
util_limite_media	media(BILL_AMT1..6) / LIMIT_BAL	Utilización media del semestre	0,128
esfuerzo_pago	PAY_AMT1 / BILL_AMT2	Parte pagada de la última factura	0,108
esfuerzo_pago_medio	Σ PAY_AMT1..5 / Σ BILL_AMT2..6	Esfuerzo de pago del semestre	0,155
tendencia_retraso	PAY_1 − PAY_6	Si el retraso empeora o se recupera	0,265
meses_en_retraso	nº de meses con PAY_n ≥ 1	Persistencia del impago	0,804

Tabla 2. *Variables derivadas incorporadas como candidatas del scorecard.*

El pago de un mes liquida la factura del mes anterior, por eso el esfuerzo de pago divide PAY_AMT1 entre BILL_AMT2. La API y los agentes calculan estas variables con la misma función, y el notebook comprueba que ambas versiones coinciden en los 30.000 titulares.

6.3. Tramificación óptima con optbinning

La tramificación se realiza con optbinning (Navas-Palencia, 2020), con un tamaño mínimo de tramo del 10 % y un máximo de cinco tramos por variable. Los estados de pago, el nivel de estudios y el estado civil se tratan como categóricas: aunque los retrasos son ordinales, los códigos negativos y el cero recogen situaciones no ordenables entre sí (sin consumo, pago al corriente, *revolving*), por lo que imponer monotonía distorsionaría la tramificación. De las 28 variables candidatas, 21 superan el umbral de IV, entre ellas las seis derivadas; quedan fuera los seis importes de factura y el estado civil.

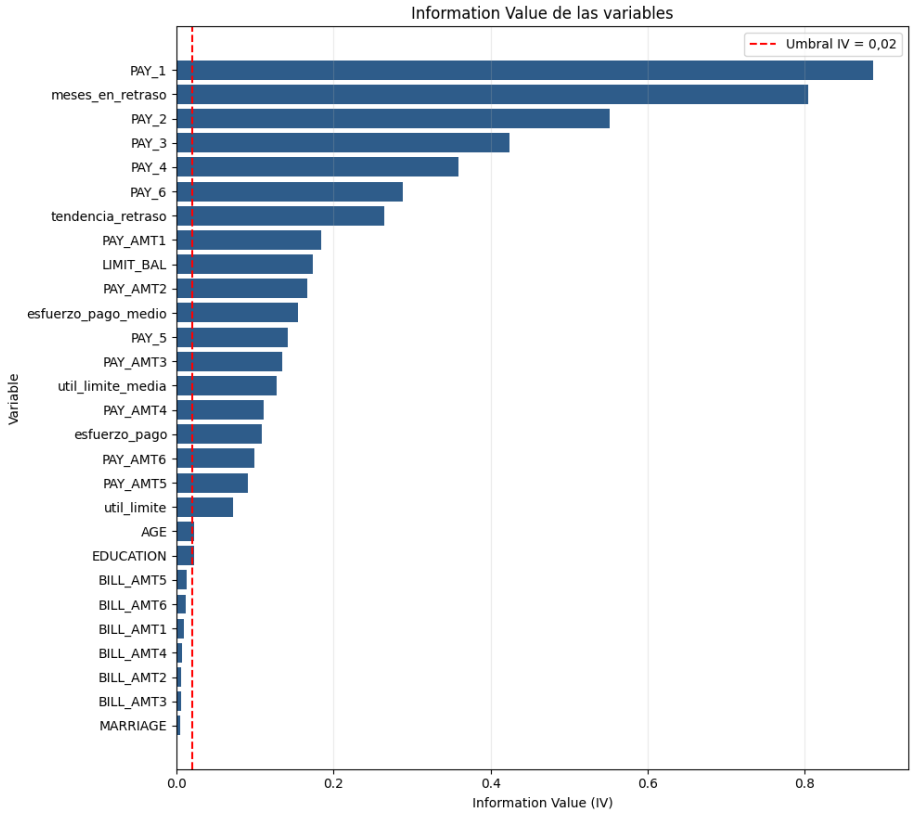


Figura 4. *Information Value de las variables.*

El nivel de deuda absoluto discrimina mal: deber cien mil dólares taiwaneses no indica por sí solo si un titular va a impagar, y por eso los importes de factura quedan fuera. Llevar meses de retraso sí lo indica: PAY_1 encabeza la tabla con un IV de 0,887, seguida de los meses en retraso, con 0,804.

6.4. Regresión logística y selección de variables

El modelo combina la tramificación con una regresión logística. Con la convención WOE todos los coeficientes deben ser negativos, pero ajustando con las 21 candidatas tres salen positivos: la tendencia del retraso (+0,133), PAY_2 (+0,073) y PAY_5 (+0,040). No carecen de información, sino que repiten la de otra: PAY_2 se correlaciona un 0,80 con PAY_3, PAY_5 un 0,82 con PAY_4, y la tendencia es PAY_1 − PAY_6. El modelo las usa para compensar a sus gemelas, y un signo cambiado haría que un tramo sumara puntos en sentido contrario al riesgo, inaceptable en un *scorecard* auditable.

En lugar de eliminar variables de forma mecánica, se descartan de entrada las que son redundantes por construcción. PAY_2 a PAY_6 se sustituyen por PAY_1, el mes más reciente y la señal más fuerte, junto con los meses en retraso, que resumen el resto del historial; la tendencia sobra porque ya están sus dos componentes; y de la utilización y el esfuerzo de pago se conserva la media del semestre, que distingue al titular apalancado de forma crónica del que tuvo un mes malo. El modelo se queda con lo más reciente y lo acumulado, y prescinde de las variables intermedias que combinan ambas cosas.

Con esta selección todos los coeficientes salen negativos a la primera, lo que confirma que los signos invertidos los causaba la redundancia; la revisión de signos se mantiene igualmente como red de seguridad. El modelo final tiene 13 variables, entre ellas tres derivadas. La regla para aceptarlo se fijó antes de ver el resultado: la pérdida de AUC en validación cruzada debía ser menor que la dispersión entre particiones. Es de 0,0009 (0,7730 frente a 0,7739), frente a una dispersión de 0,0121, de modo que simplificar no cuesta capacidad predictiva.

La calibración a escala de puntuación emplea el método PDO/*odds* con PDO = 20 puntos, *odds* de referencia 1/19 y puntuación de referencia 600 (Siddiqi, 2017). El anclaje equivale a una tasa de evento del 5 %, inferior al 22,1 % observado, por lo que la cartera se concentra entre 637 y 779 puntos; la interpretación de negocio se realiza sobre la PD y no sobre el nivel absoluto de puntos.

El modelo se reduce a una tabla de puntos donde cada dato del cliente suma o resta una cantidad conocida. Un gestor puede explicar cualquier puntuación señalando el tramo que ocupa el cliente en cada variable, y el área de riesgos puede revisar la tabla sin ejecutar código.

	Variable	Tramo	Puntos
0	PAY_1	[-2, 0]	67.67
1	PAY_1	[-1]	61.29
2	PAY_1	[1]	44.58
3	PAY_1	[5, 8, 6, 4, 2, 3, 7]	17.22
4	PAY_1	Special	55.46
5	PAY_1	Missing	55.46
6	meses_en_retraso	(-inf, 0.50)	63.88
7	meses_en_retraso	[0.50, 1.50)	50.93
8	meses_en_retraso	[1.50, inf)	40.44
9	meses_en_retraso	Special	55.46
10	meses_en_retraso	Missing	55.46

Tabla 3. *Extracto de la scorecard resultante.*

La Tabla 3 muestra un extracto de la tabla de puntos del *scorecard* final para dos de las variables más relevantes del modelo: ‘PAY_1’ y ‘meses_en_retraso’. Cada tramo de valores tiene asignada una puntuación que contribuye al resultado final del cliente. De este modo, el modelo no solo permite estimar el riesgo de impago, sino también justificar la puntuación obtenida a partir de las características del solicitante. Esta representación facilita la interpretación de los resultados y su revisión por parte del área de riesgos, al hacer explícita la contribución de cada tramo sin necesidad de consultar directamente los coeficientes de la regresión logística.

7. Validación del modelo

7.1. Diagnóstico dentro y fuera de muestra

El modelo se evalúa con las métricas estándar de discriminación (AUC-ROC, KS y curva CAP) en entrenamiento y test. La diferencia entre ambos es reducida (0,0169 de AUC), sin indicios de sobreajuste apreciable.

Métrica	Train	Test
AUC-ROC	0,7763	0,7594 (IC 95 %: 0,7433 – 0,7745)
Gini	0,5527	0,5188
KS	0,4149	0,3949
Brier score	-	0,1390
AUC validación cruzada 5-fold	0,7730 ± 0,0121	-
PSI (train vs test)	-	0,0030

Tabla 4. *Métricas de discriminación, calibración y estabilidad del scorecard.*

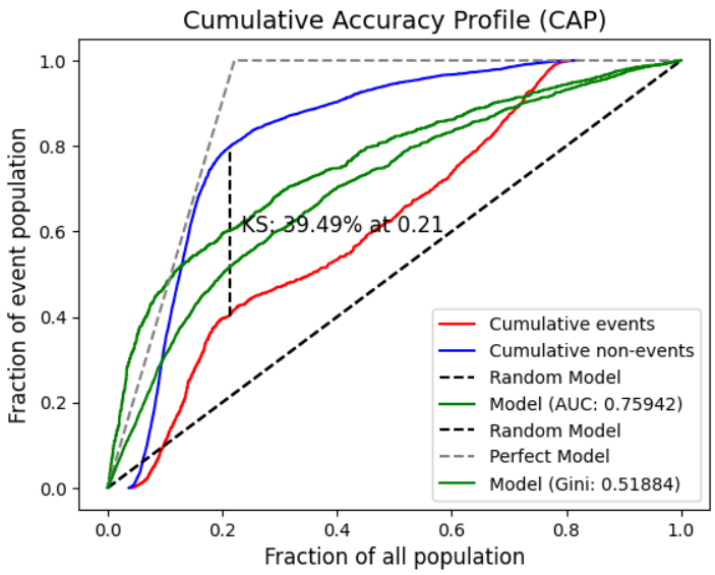


Figura 5. *Curva CAP del scorecard en test.*

7.2. Validación cruzada estratificada

La validación cruzada estratificada de cinco particiones repite el procedimiento completo en cada una: tramificación, selección por IV y revisión de signos. Mide así el método y no solo el modelo final, y la dispersión entre particiones es reducida (0,7730 ± 0,0121).

7.3. Calibración y estabilidad

Debido a que el modelo alimenta el cálculo de provisiones y la regla del punto de corte, no basta con que discrimine: la probabilidad debe estar calibrada, es decir, que una PD del 20 % corresponda a una frecuencia de impago próxima al 20 %. El diagrama de fiabilidad y el Brier score lo confirman, y el *backtesting* por deciles muestra desviaciones de menos de 2,1 puntos en siete de los diez deciles; en los deciles 7 a 9 la desviación es de entre 3 y 4 puntos, con el modelo infraestimando en el séptimo (17,7 % frente a 21,8 %) y sobreestimando en el octavo y el noveno. La PD media de la cartera (0,220) coincide con la tasa observada (0,221).

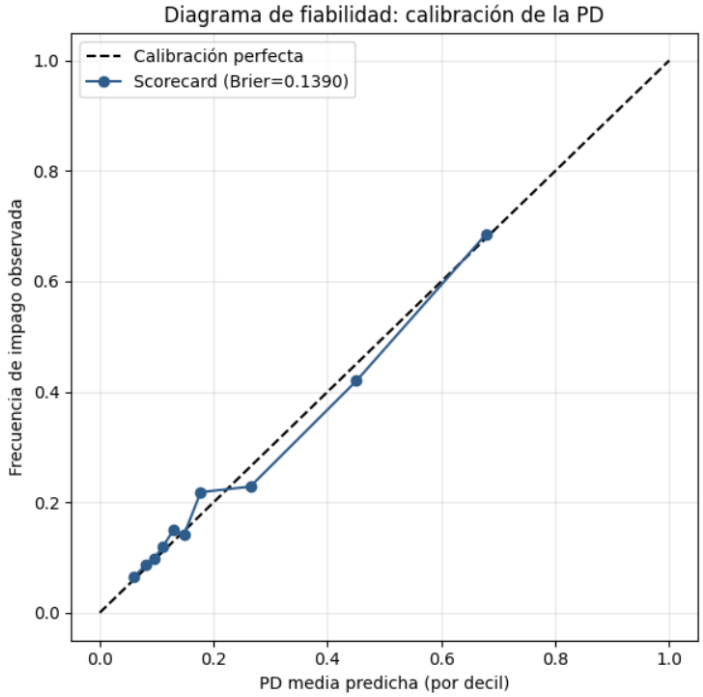


Figura 6. *Calibración de la probabilidad de impago (diagrama de fiabilidad).*

El *Population Stability Index* (PSI) entre entrenamiento y test es de 0,0030, pero conviene precisar su alcance: al proceder ambas muestras de una partición aleatoria del mismo corte, un PSI próximo a cero es el resultado esperado por construcción. Verifica la partición, no la estabilidad futura: queda implementado para aplicarlo en producción a cada ventana mensual, con umbrales de 0,10 para revisión y 0,25 para recalibración, junto con el *backtesting* de la calibración.

7.4. Validación desplazada en el tiempo

El dataset no tiene fechas, pero sí seis meses de historial ordenados en el tiempo, lo que permite una validación fuera de tiempo real. Se construye un *scorecard* con la misma metodología sobre una ventana (abril a junio para predecir julio) y se evalúa, sin reentrenar, sobre la siguiente (mayo a julio para predecir agosto). El evento es un retraso de dos o más meses, que se codifica igual en todas las columnas.

El modelo se mantiene fuera de tiempo: el AUC pasa de 0,860 a 0,875, y la PD media predicha para agosto (0,151) queda muy próxima a la tasa observada (0,146). La ventana de septiembre no es comparable, porque usa la columna PAY_1 codificada de forma distinta. El evento es aproximado, los titulares son los mismos y el horizonte es de un mes: valida que la relación entre historial y morosidad es estable, sin sustituir a un *backtesting* de varios ejercicios. Para la entidad, significa que un modelo construido con el comportamiento de un mes sigue ordenando bien a los clientes al mes siguiente, sin necesidad de reentrenarlo cada vez que llega un nuevo dato.

7.5. Punto de corte sensible al coste

Los dos errores no cuestan lo mismo. Un falso negativo, tratar como sano a quien acaba en impago, hace perder el principal no recuperado (LGD × EAD). Un falso positivo, tratar como riesgo a un buen pagador, cuesta la gestión del caso y, sobre todo, el margen de intereses que se deja de ganar al recortarle el límite. Con una PD calibrada, el corte que minimiza el coste esperado tiene fórmula cerrada: conviene marcar al titular cuando PD × LGD supera a (1 − PD) × c, siendo c el coste del falso positivo sobre el saldo, es decir, cuando la PD supera c / (LGD + c). El EAD se cancela, y como el corte sale de una fórmula y no de una búsqueda sobre los datos, no introduce fuga.

Si *c* recoge solo la gestión (2 % del saldo), el corte cae a 0,043, apenas por encima de la PD mínima de la cartera (0,038), y la regla marca al 99,7 % de los titulares. Por eso *c* incluye un margen perdido del 8 %, supuesto que en una entidad real saldría del rendimiento de la cartera. Con *c* = 10 %, el corte queda en 0,182, frente al corte neutro de 0,221 que fija la tasa de impago. La regla supone una PD calibrada, y el corte cae en el séptimo decil, justo donde el *backtesting* muestra la mayor desviación: el modelo infraestima allí el riesgo en unos cuatro puntos. Conviene por tanto revisar el corte con el *backtesting* de cada ventana.

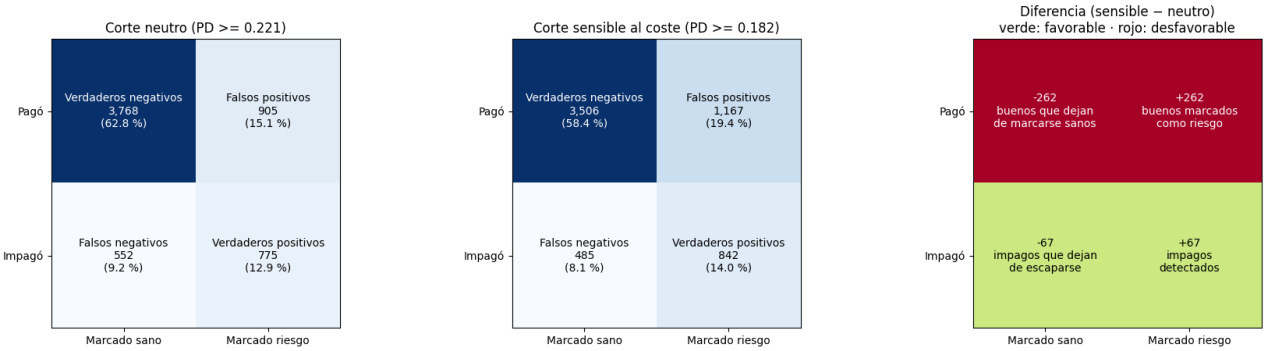


Figura 7. *Matrices de confusión con el corte neutro y el corte sensible al coste, y diferencia entre ambas.*

El corte sensible al coste detecta 67 impagos más (el *recall* pasa del 58,4 % al 63,5 %) a cambio de marcar 262 buenos pagadores más (la precisión baja del 46,1 % al 41,9 %), y marca como riesgo al 33,5 % de la cartera frente al 28,0 %. Dicho en términos de gestión: por cada impago adicional que se detecta, se revisa a unos cuatro buenos pagadores más. El coste total apenas varía: baja un 0,3 % con los supuestos adoptados. En esta zona la curva de coste es plana, de modo que elegir entre los dos cortes es sobre todo una decisión de apetito de riesgo. Se despliega el corte sensible al coste porque refleja la asimetría real entre los dos errores: dejar pasar un impago cuesta el principal, mientras que marcar a un buen pagador cuesta la gestión y el margen.

El modelo ordena la cartera de forma fiable, que se mantiene fuera de muestra y de tiempo, y sus probabilidades son realistas en magnitud, requisito para provisionar y para fijar el corte por coste.

8. Modelo challenger: XGBoost, SHAP y MLflow

Siguiendo el enfoque *champion-challenger* de la banca, se contrasta el *scorecard* con un modelo sin ninguna restricción de interpretabilidad: un XGBoost (Chen & Guestrin, 2016) sobre las 28 variables candidatas en crudo, incluidas las que el IV y selección descartaron, con hiperparámetros optimizados por búsqueda aleatoria y validación cruzada sobre el entrenamiento. Como los dos modelos disponen de la misma información, su diferencia mide lo que cuesta la interpretabilidad.

8.1. Trazabilidad con MLflow

Ambos modelos se registran en MLflow, que almacena sus hiperparámetros, métricas y artefactos bajo un mismo experimento, generando el registro auditable que exige el gobierno del modelo.

```
Experimento: credit_risk_taiwan
Runs registrados: 2
```

	Modelo	AUC test	n_estimators	max_depth	Fecha	Gini
0	xgboost_sin_restricciones	0.7858	300	5	2026-10-16 08:45	0.5716
1	scorecard_champion	0.7594	None	None	2026-10-16 08:44	0.5188

Figura 8. *Registro de experimentos en MLflow.*

8.2. Comparativa y explicabilidad

Mostramos una tabla comparativa de ambos modelos:

Modelo	AUC test	Gini	Brier	ΔAUC vs champion (IC 95 %)
Scorecard (champion, 13 var.)	0,7594	0,5188	0,1390	—
XGBoost sin restricciones (28 var.)	0,7858	0,5715	0,1765	+0,0263 [+0,0197, +0,0327]

Tabla 5. *Comparativa del champion frente al challenger sobre la muestra de test.*

La diferencia de AUC se acompaña de un intervalo de confianza *bootstrap* emparejado, que remuestrea las mismas observaciones para ambos modelos y aísla así la diferencia del error muestral común. La ventaja del XGBoost, de 2,6 puntos de AUC, es distinguible del ruido. SHAP (Lundberg & Lee, 2017) resuelve su opacidad: la variable más influyente es una derivada, los meses en retraso, seguida de PAY_1. En tercer lugar aparece el saldo de la última factura, que el *scorecard* descarta por su IV de 0,010: por sí solo discrimina mal, pero el XGBoost lo combina con el límite y el resto de variables. Parte de su ventaja procede, por tanto, de interacciones que un modelo aditivo sobre tramos no puede representar.

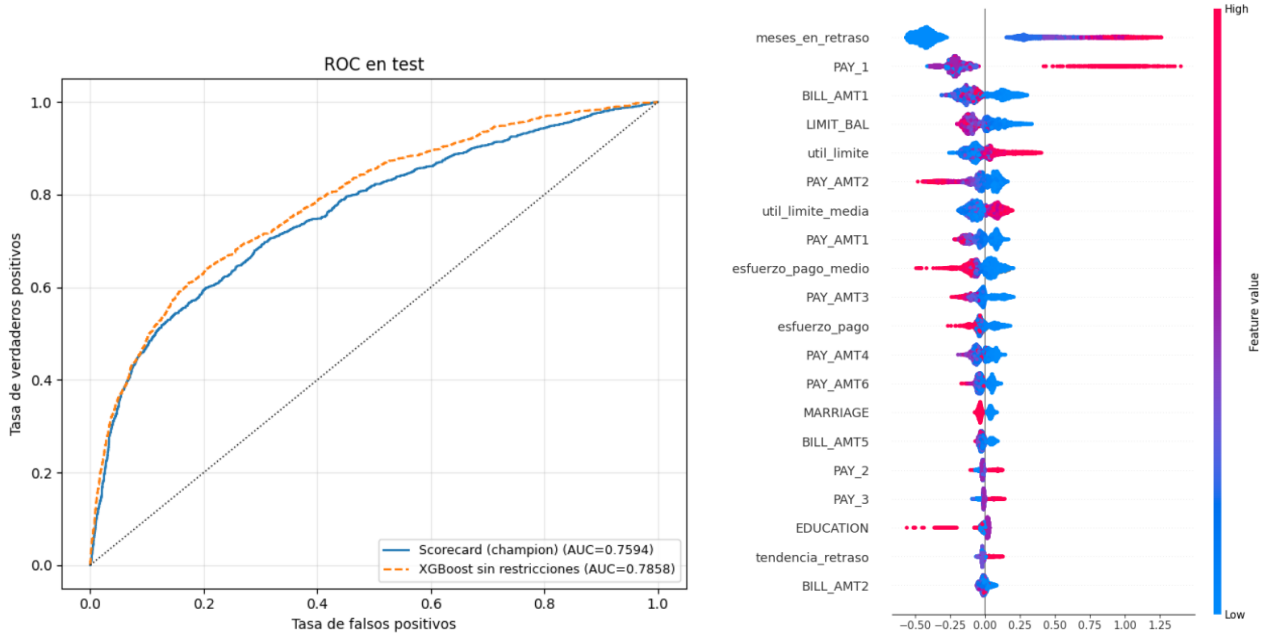


Figura 9. *Comparativa ROC del champion y el challenger, y explicabilidad SHAP del XGBoost.*

El *scorecard* se mantiene como modelo en producción, y la razón principal es la auditabilidad: una tabla de puntos se justifica ante el supervisor con el tramo que ocupa el cliente en cada variable, sin reconstruir después por qué decidió el modelo, y esa misma explicación puede darse al titular.

SHAP describe el comportamiento del XGBoost, pero no lo convierte en una regla que pueda revisarse línea a línea. A ello se suma un coste operativo: el XGBoost reequilibra las clases y descalibra su probabilidad, con una PD media de 0,416 frente a una tasa observada de 0,221 y un Brier score de 0,177 frente a 0,139. Podría recalibrarse, pero sería un componente más que validar y mantener antes de usar su salida para provisionar o para fijar el corte. La ganancia de 2,6 puntos existe y está cuantificada: es el precio de la interpretabilidad.

9. Aplicación práctica e IFRS 9

La PD del *scorecard* estima la probabilidad de retraso en el mes siguiente. La IFRS 9 pide otra cosa: la probabilidad de *default* a 12 meses en el Stage 1 y a toda la vida en los Stages 2 y 3. Se construye con una cadena de Markov sobre tres estados (al corriente, de 30 a 89 días y *default* a 90 días o más, absorbente), con las 94.861 transiciones mensuales de abril a agosto del entrenamiento. Un titular al corriente pasa a mora un 4,9 % de las veces cada mes; uno en mora se recupera un 30,2 % y entra en *default* un 6,0 %. Elevando la matriz al horizonte, la PD a 12 meses es del 6,8 % desde al corriente y del 20,7 % desde mora, y a 36 meses, vida conductual supuesta para una tarjeta, del 21,9 % y del 33,6 %.

La PD de *default* se asigna por tramo de retraso: es una evaluación colectiva, habitual en carteras minoristas. Se descartó escalarla por el riesgo relativo del *scorecard* dentro de cada estado, porque la PD de vida bajaba al empeorar el estado de pago. El *scorecard* conserva su papel en la ordenación, la decisión y el criterio cuantitativo de *stage*.

Los *stages* siguen los criterios de la norma: Stage 3 con 90 días o más de retraso, Stage 2 con más de 30 días o con una PD superior a 0,35 como criterio cuantitativo, y Stage 1 el resto. La exposición incorpora un factor de conversión estimado con los 314 titulares que entran en *default* en agosto, comparando su saldo con el de cuatro meses antes: el CCF medio es de 0,324, con una distribución en forma de U (unos agotan el límite y otros no lo tocan). Aplicarlo eleva la exposición de la cartera un 75 % y da exposición a los 523 titulares de test con saldo nulo.

Stage	Clientes	Con umbrales de PD	EAD (NT$)	ECL (NT$)	% del ECL	Cobertura
1	4.598	3.360	443.294.664	13.509.725	44,7 %	3,05 %
2	1.329	1.429	95.852.023	14.437.640	47,8 %	15,06 %
3	73	1.211	5.063.984	2.278.793	7,5 %	45,00 %
Total	6.000	6.000	544.210.671	30.226.158	100 %	5,55 %

Tabla 6. *Asignación de stages IFRS 9 y pérdida esperada sobre la cartera de test.*

La provisión total asciende a 30,2 millones de NT$, un 5,6 % de la exposición, y la cobertura crece con el *stage*: 3,0 %, 15,1 % y 45,0 %, el patrón esperable en una cartera real. La columna intermedia muestra el reparto anterior, por umbrales de PD, que clasificaba como deteriorado al 20,2 % de la cartera cuando solo el 1,2 % lleva 90 días o más de retraso.

Cruzada con la capacidad de pago, la clasificación admite una lectura de gestión: un titular de Stage 3 que sigue abonando algo cada mes es candidato a refinanciación o plan de pagos, y uno que ha dejado de pagar, a recobro formal; en el Stage 2 la acción es preventiva. Revisar el límite a la baja protege a la entidad, pero no ayuda a pagar a quien ya está en mora. Es una propuesta de gestión no validada, porque el dato observa un único mes de desenlace.

Conviene declarar los supuestos. La cadena de Markov se supone homogénea en el tiempo y sin memoria, y se estima con cuatro transiciones. La falta de memoria choca con el propio *scorecard*, cuya segunda variable más potente es la persistencia del impago: la PD de vida probablemente infraestima a los morosos crónicos y sobreestima a los ocasionales. La LGD del 45 % es un valor convencional y no una estimación propia; en tarjetas sin garantía las LGD reales suelen ser mayores y el suelo regulatorio para estas exposiciones es del 50 %, y la provisión pasa de 30,2 a 43,7 millones con una LGD del 65 % y a 57,1 con una del 85 %. El CCF se estima con una muestra pequeña y una ventana de cuatro meses. Por ello, todas las interfaces muestran de forma permanente que el ECL es ilustrativo y no apto para provisionar. Los parámetros estimados se guardan con el modelo serializado y los parámetros de riesgo se centralizan en config_riesgo.py, que consumen el notebook, la API y los agentes.

10. Modelo de recobro

El *scorecard* de comportamiento decide a quién vigilar; un segundo modelo decide cómo actuar con quien ya está en mora. En tarjetas, la mora se gestiona por tramos de retraso, y cada tramo tiene su estrategia: tratamiento suave al principio, planes de pago después y gestión especializada al final. El modelo estima, para cada titular en mora, la probabilidad de que no se recupere el mes siguiente, y concreta con datos la lectura de gestión del capítulo 9 para la mora de 60 días; el Stage 3 queda fuera de su alcance. El desarrollo completo se recoge en el Anexo 8.

10.1. Diseño y validación

Cada observación es un titular en mora en un mes y su situación al mes siguiente: 12.376 observaciones de 6.408 titulares, con una tasa de no recuperación en torno al 70 %. Las variables usan solo información disponible en el mes de la mora, como el estado de pago del mes anterior, la utilización del límite o el esfuerzo de pago. Se aplica la misma metodología que al *scorecard*, con tramificación WOE, selección por IV y revisión de signos, que elimina los meses previos en mora y la variación de la deuda. Se entrena con la mora de abril a junio y se evalúa fuera de tiempo con la de julio, con validación cruzada agrupada por titular, para que un mismo titular no esté a la vez en las dos muestras.

El modelo alcanza un AUC de 0,707 en validación cruzada y de 0,738 fuera de tiempo. Como el 62 % de los titulares de julio ya había estado en mora antes, se mide también sobre el 38 % restante, que el modelo no había visto: 0,708, en línea con la validación cruzada. Además, está calibrado en media: en julio, la PD media es de 0,683 frente a una tasa observada de 0,680. Por deciles, la desviación llega a unos cuatro puntos y a seis en el último (0,898 frente a 0,838). Las cifras son coherentes con la cadena de Markov del capítulo 9: la tasa de no recuperación del 70 % equivale a 1 − 30,2 %, y el paso a 90 días (6,1 %) coincide con el 6,0 % de esa matriz.

10.2. Estrategias de recobro

La probabilidad se traduce en tres estrategias, con cortes en los terciles del entrenamiento, 0,664 y 0,793, de modo que la evaluación no interviene en su definición. Los terciles son una convención de reparto y no un óptimo: al fijarse con el entrenamiento y aplicarse a meses posteriores, el tamaño de cada grupo se desplaza (en julio, 43 %, 14 % y 43 %). En una entidad real los cortes los fijarían la capacidad del equipo de gestión y el coste de cada acción, de forma análoga al corte por coste del capítulo 7.

Estrategia	Acción	Titulares en mora	Saldo en riesgo
Recordatorio	Aviso automático	1.604	40.678.810
Plan de pagos	Llamada con propuesta de fraccionamiento	682	11.849.547
Gestión especializada	Contacto prioritario y estudio de refinanciación	1.669	94.877.248

Tabla 7. *Estrategias de recobro sobre la mora de agosto.*

Como la mayoría de los titulares en mora no se recupera, el valor del modelo no está en encontrar a quien no lo hará, sino en identificar a la minoría que se recupera sola, para no dedicarle una gestión cara: en julio, el segmento de recordatorio reunía al 70 % de quienes se recuperaron solos con el 43 % de la mora. La tasa de no recuperación crece con claridad de una estrategia a otra, del 48 % al 86 %, mientras que el paso a 90 días apenas cambia.

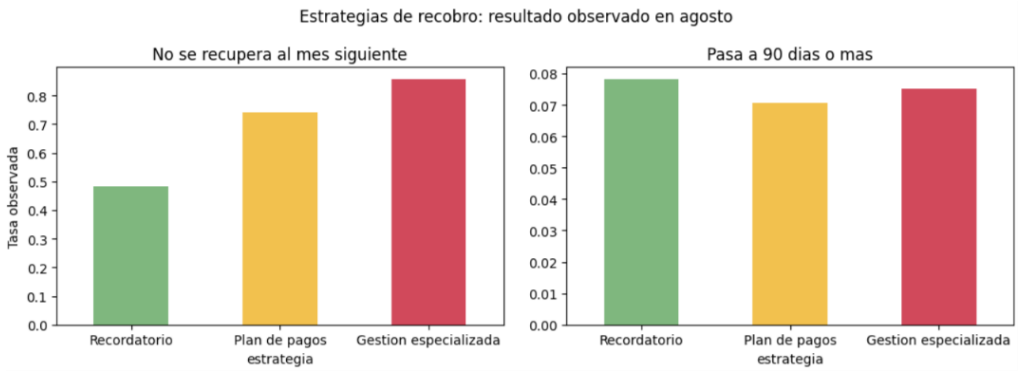


Figura 10. *Resultado observado en agosto de la mora de julio, por estrategia de recobro.*

En el otro extremo, la gestión especializada concentra el 64 % del saldo en riesgo, que combina la probabilidad de no recuperarse con el saldo. Las alertas se ordenan por ese saldo en riesgo, los mensajes al titular se generan en código a partir de la estrategia, y el agente del gestor las consulta como una herramienta más (capítulo 12).

10.3. Alcance

Por la codificación del *dataset*, la mora de un mes casi no aparece antes de septiembre, de modo que el modelo es de segundo tramo, de 60 días, y no cubre el de 30, donde más titulares se recuperan solos. El horizonte es de un mes, mientras que en tarjetas la deuda no recuperada suele darse por perdida mucho más tarde, un desenlace que seis meses de datos no permiten observar. El modelo separa la recuperación, pero no el paso a 90 días, que apenas varía entre estrategias (del 7,1 % al 7,8 %). El saldo en riesgo usa solo el saldo dispuesto porque, con ese retraso, la tarjeta suele estar bloqueada para nuevas compras. Las estrategias son una propuesta: su efecto real se mediría con un experimento, comparando titulares contactados y no contactados. El modelo no utiliza el sexo, pero no se ha sometido al análisis de equidad del capítulo 5.

11. Puesta en producción: API REST con FastAPI y Docker

Siguiendo el enfoque de productivización trabajado en el máster (Materiales docentes del máster, 2025/2026), el modelo se expone como un microservicio REST mediante FastAPI. La aplicación carga el modelo serializado al arrancar, comprueba que su configuración incluye los parámetros IFRS 9 y valida las peticiones con esquemas Pydantic, que restringen los rangos admisibles de cada variable (por ejemplo, EDUCATION entre 1 y 4).

11.1. Endpoints y validación

El servicio expone tres endpoints:

Endpoint	Función
/info	Metadatos del modelo: versión, punto de corte, parámetros IFRS 9 y estado de autenticación.
/health	Estado del servicio. Siempre accesible, para comprobaciones de disponibilidad.
/predict	Recibe los datos del cliente en JSON y devuelve PD, PD a 12 meses y de vida, score, decisión, EAD, ECL, *stage* y aviso.

Tabla 8. *Endpoints expuestos por el servicio.*

El servicio calcula las variables derivadas y pasa al modelo exactamente las columnas que espera. Los *endpoints* de predicción exigen una clave de acceso. Las solicitudes de menores de 18 años se rechazan antes de puntuar, por incapacidad legal para contratar. Como la edad mínima en

entrenamiento es de 21 años, el tramo de 18 a 20 es una extrapolación. FastAPI genera documentación interactiva en /docs. La API no expone el modelo de recobro: sus alertas se precalculan y las consulta el agente del gestor (capítulo 12).

Para la entidad, cualquier canal (web, app móvil o una oficina) puede pedir la evaluación al mismo servicio y obtener la misma respuesta, y una actualización del modelo llega a todos a la vez.

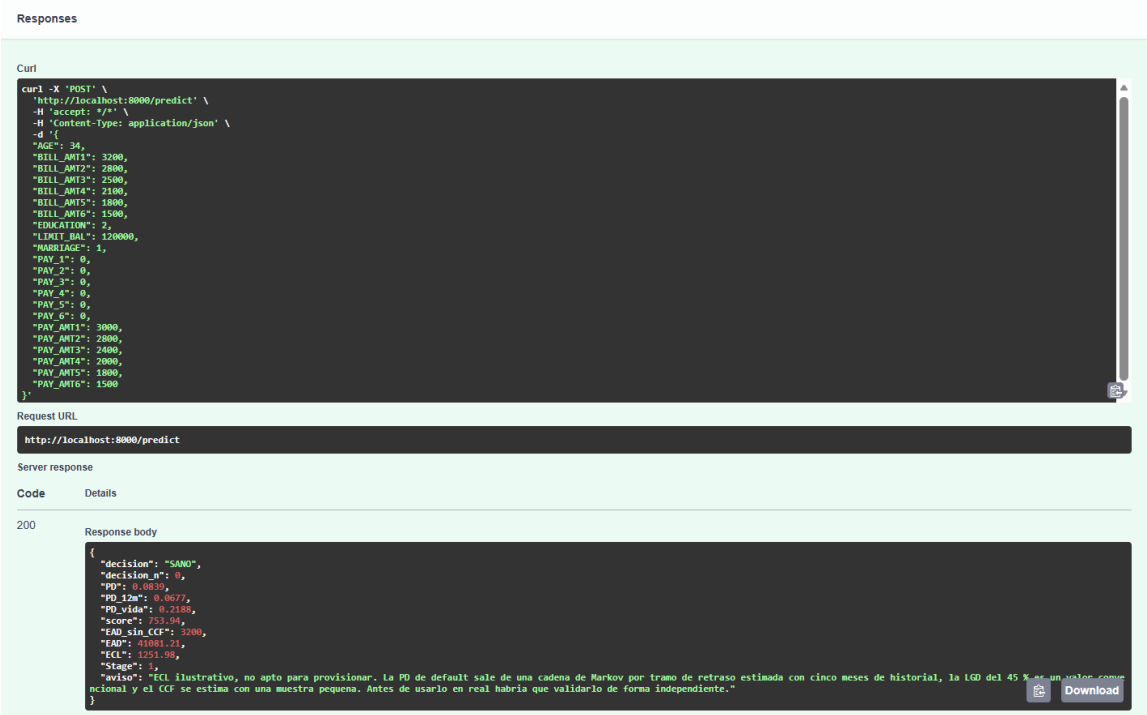


Figura 11. *Documentación interactiva de la API.*

11.2. Contenerización

El servicio se empaqueta en una imagen Docker basada en Python 3.11 que instala las dependencias y arranca uvicorn en el puerto 8000. La versión de scikit-learn se fija en la misma con la que se serializa el modelo, para que la imagen lo cargue sin incompatibilidades. El código del servicio, el Dockerfile y las pruebas se aportan en el Anexo 5.

12. Integración operativa: agentes conversacionales

El modelo se integra en dos agentes construidos con Streamlit y LangChain, con un modelo de lenguaje de pesos abiertos (gpt-oss-120b) servido mediante Groq. Comparten el *scorecard* serializado y los parámetros de riesgo, y se diferencian en el destinatario: uno atiende al titular y otro al gestor de cartera.

12.1. Canal al titular: pre-evaluación orientativa

Es una herramienta de pre-evaluación para el cliente: sin pedir ningún identificador, recopila el estado de pago, el importe pagado y la factura de cada uno de los seis meses, y devuelve una estimación no vinculante de su riesgo y de si su límite se mantendría o convendría revisarlo. La propuesta de revisión aplica un criterio de gestión definido para este trabajo, que reduce el límite en proporción a la PD; no es una política calibrada, y en una entidad real el nuevo límite lo fijaría su política de riesgo. Dispone de tres herramientas: el cálculo del *scoring*, la recomendación de perfiles de bajo riesgo similares mediante KNN y el guardado opcional de la consulta previo consentimiento.



Figura 12. *Ejemplo de salida del agente conversacional sobre la evaluación de riesgo.*

El LLM no interviene en el cálculo: la PD, la puntuación y el *stage* se resuelven en las herramientas, y el modelo de lenguaje solo conduce la conversación. Esta separación permite sustituir el proveedor del LLM sin revalidar el modelo de riesgo. El mismo principio rige la explicación: los factores que elevan el riesgo se calculan en código como el producto del coeficiente por el WOE de cada tramo, y el agente tiene prohibido justificar la decisión con cualquier otro dato.

El diseño aplica minimización de datos (artículo 5.1.c del RGPD), ya que solo se piden las variables que intervienen en el cálculo, y consentimiento explícito para el guardado, sin vincularlo a la identidad del titular. Al tratarse de una evaluación orientativa sin efectos jurídicos, no constituye una decisión automatizada en el sentido del artículo 22. La consulta se guarda sin desenlace, para que un reentrenamiento no aprenda de la propia salida del sistema.

El valor del canal está también en el momento: sin él, el titular descubre la revisión de su límite cuando ya está decidida, y con él puede anticiparla. Es un ejercicio de transparencia coherente con el eje del sistema, porque el criterio que exige justificar una decisión ante el supervisor exige poder explicársela al cliente; y revisar un límite a la baja también limita el endeudamiento de quien ya muestra tensión de pago.

12.2. Canal al gestor: asistente de cartera

Un canal conversacional rinde cuando quien pregunta no dispone del dato, como el gestor ante 30.000 titulares. No introduce variables: pregunta sobre la cartera ya puntuada y dispone de cinco herramientas, que devuelven cifras agregadas, rankings, fichas individuales con sus factores y su estrategia de recobro, un contrafactual sobre el estado de pago y las alertas de recobro ordenadas por saldo en riesgo. Las herramientas ejecutan consultas parametrizadas y el modelo solo elige cuál invocar: permitirle redactar SQL introduciría un riesgo distinto del de una alucinación, una consulta válida que responde a otra pregunta.

El ranking ordena por pérdida esperada y no por PD, porque el ECL incorpora la exposición. Al gestor se le muestran el *stage* y el ECL, información contable de la entidad que al titular no se le

ofrece, siempre con el aviso permanente de su carácter ilustrativo. Las alertas de recobro corresponden a la mora de agosto, precalculada, y se ordenan por saldo en riesgo; la estrategia, la acción y el mensaje al titular los fija el modelo de recobro (capítulo 10) y el agente se limita a comunicarlos.

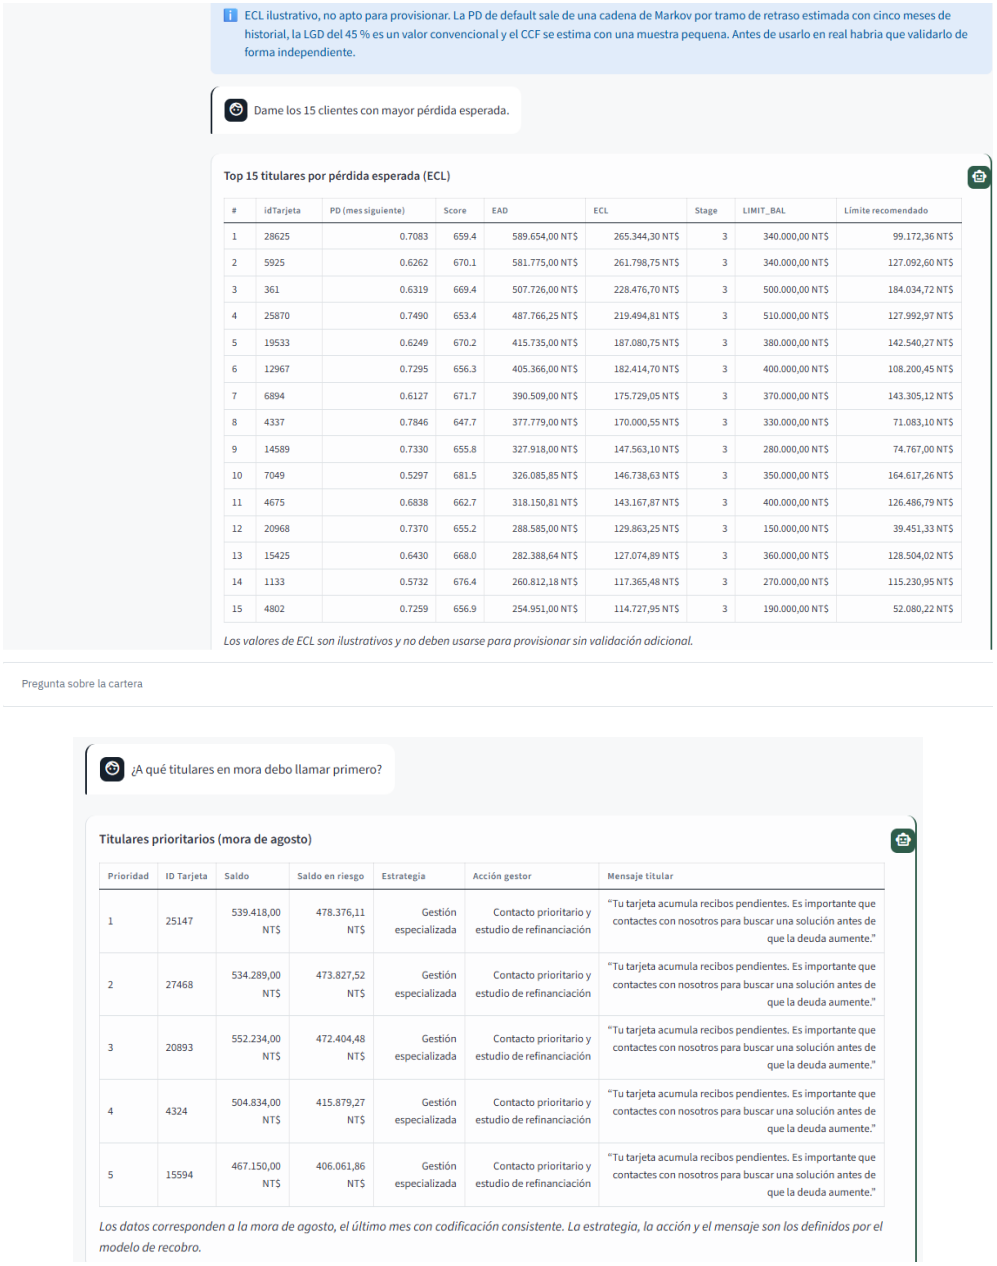


Figura 13. *Ejemplos de salida del asistente de carteras.*

12.3. Trazabilidad en todas las capas

Las pruebas produjeron dos veces el mismo hallazgo. El primer asistente del titular justificaba la decisión citando el saldo pendiente, que no entraba en el modelo: construía una explicación plausible por su cuenta. En el del gestor, el modelo no calculó mal ninguna cifra, pero al redactar reinterpretó el separador decimal y multiplicó los importes por mil. En ambos casos la solución fue invertir la responsabilidad: el dato se calcula y se formatea en código, y el asistente solo puede comunicarlo. Un modelo interpretable no garantiza un sistema interpretable: la trazabilidad hay que sostenerla en todas las capas, incluidas las que hablan con el cliente. El código de los agentes se recoge en el Anexo 2.

13. Visualización ejecutiva en Tableau

Para la monitorización de negocio se construye un dashboard en Tableau conectado a los datos exportados del modelo. Cubre la visión agregada que necesita un analista de riesgos y la consulta individual de un titular, en la que la contribución de cada variable se calcula como el producto del coeficiente por el WOE de su tramo, la misma descomposición que emplean los agentes.

13.1. Vistas del dashboard

El *dashboard* incluye una vista de KPIs globales (tasa de *default* esperada, ECL total y distribución por *stage* IFRS 9, con el aviso de su carácter ilustrativo), una vista de riesgo por perfil y una vista de consulta individual por identificador de cliente. El *dashboard* no incorpora las alertas de recobro. Los datos y el enlace al *dashboard* en Tableau Public se aportan en el Anexo 7.

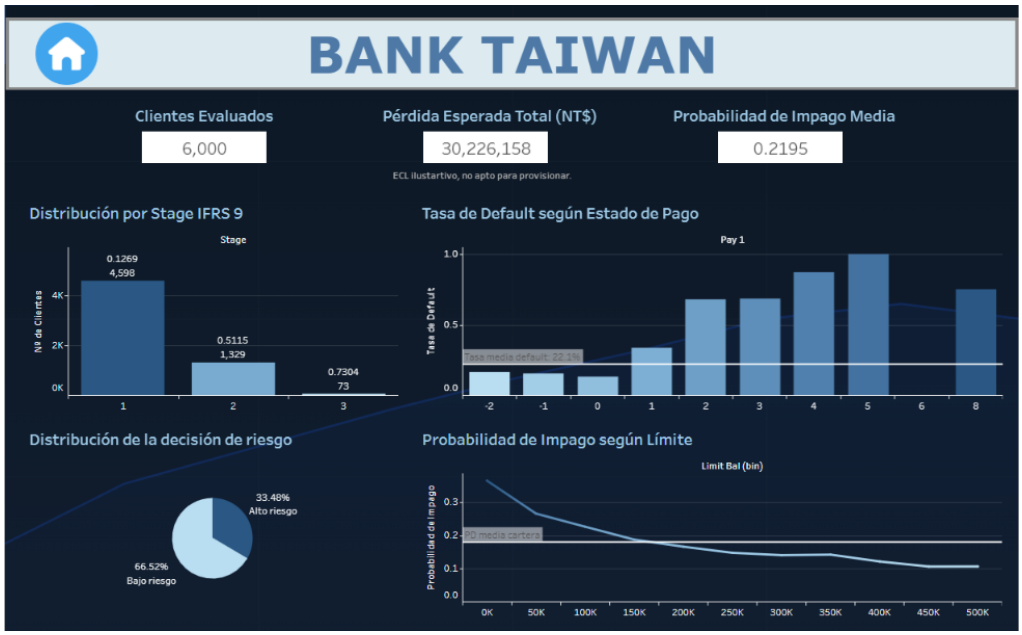


Figura 14. *Dashboard ejecutivo de monitorización de la cartera.*

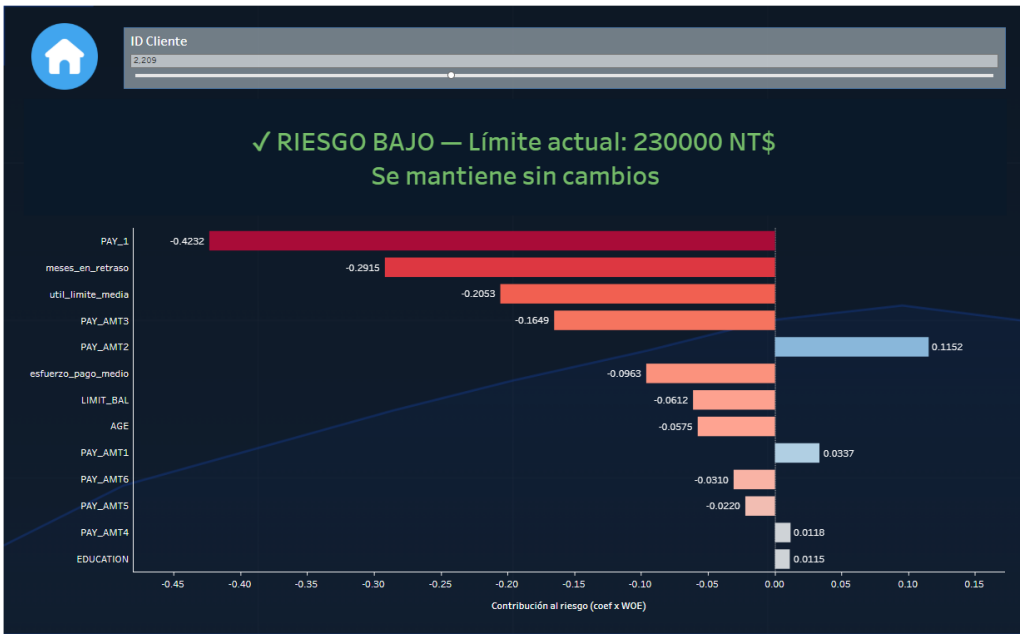


Figura 15. *Vista individual: descomposición de la PD en la contribución de cada variable y decisión.*

14. Conclusiones y líneas futuras

14.1. Conclusiones

Una entidad con cartera de tarjetas no puede esperar a que un cliente deje de pagar para reaccionar, ni provisionar a ciegas. El sistema desarrollado responde a ambas necesidades: ordena la cartera por riesgo de forma estable fuera de muestra y fuera de tiempo, y la traduce a cifras que el negocio usa directamente: una probabilidad de impago, una puntuación comparable entre clientes y una pérdida esperada en NT$ por *stage*. El gestor no solo sabe quién es el cliente más arriesgado, sino cuánto cuesta y qué acción le corresponde.

- Decisiones explicables: cada puntuación se descompone en el peso de cada dato del cliente, con variables elegidas por criterio de negocio y todos los coeficientes en el sentido esperado, de modo que ante una denegación puede decirse qué la motivó.
- Sesgo: el sexo queda fuera del modelo y se comprueba, sobre cinco muestras distintas, que el sistema no penaliza a ningún grupo de forma apreciable y que el resto de variables no lo reconstruye por vía indirecta.
- Un corte con criterio de negocio: el umbral refleja la asimetría entre dejar pasar un impago y molestar a un buen pagador, y se obtiene de una fórmula sin ajustarlo sobre los datos de evaluación.
- Provisiones con estructura de IFRS 9: PD a 12 meses y a toda la vida, *stages* por los criterios de retraso de la norma y exposición con factor de conversión, con los supuestos declarados.
- Un modelo en producción, no un cuaderno de análisis: disponible como servicio, consultable desde dos canales con destinatarios distintos y visible en un cuadro de mando, con los parámetros de riesgo centralizados.
- Coste de la interpretabilidad medido: un modelo sin restricciones ordena mejor la cartera en 2,6 puntos de AUC, pero no puede auditarse tramo a tramo, y sus probabilidades exigirían recalibrarse antes de provisionar.
- Recobro con datos: para los titulares en mora de 60 días, un segundo modelo estima la probabilidad de que no se recuperen (AUC de 0,738 fuera de tiempo y de 0,708 sobre titulares nuevos) y la traduce en tres estrategias; el recordatorio reúne al 70 % de quienes se recuperan solos con el 43 % de la mora.

El sistema no sustituye la política de riesgo: el punto de corte y los umbrales de provisión son decisiones de negocio que el modelo cuantifica, pero no toma.

14.2. Líneas futuras

- Estimar una matriz de transición por tramo de puntuación, que recoja la persistencia del impago e individualice la PD de vida sin perder su monotonía.
- Despliegue en cloud con autoescalado, y uso de datos actuales con fechas, recuperaciones y burós de crédito.
- Explicaciones contrafactuales accionables para el titular: qué cambios en su comportamiento de pago mantendrían su límite.
- Desarrollar un modelo de admisión complementario para clientes sin historial previo en la entidad.
- Ampliar el recobro al tramo de 30 días y a un segundo evento (el paso a 90 días) con datos actuales, y medir el efecto de las estrategias con un experimento de contacto.

Bibliografía

Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning*. fairmlbook.org.

Basel Committee on Banking Supervision (2017). *Basel III: Finalising post-crisis reforms*. Bank for International Settlements.

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD '16*.

Directiva 2004/113/CE del Consejo, de 13 de diciembre de 2004, sobre igualdad de trato entre hombres y mujeres en el acceso a bienes y servicios.

Elkan, C. (2001). The foundations of cost-sensitive learning. *Proceedings of the 17th International Joint Conference on Artificial Intelligence*, 973–978.

IFRS Foundation (2014). *IFRS 9 Financial Instruments*. IASB.

Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *NIPS*.

Materiales docentes del Máster en Big Data, Data Science e Inteligencia Artificial (2025/2026). Universidad Complutense de Madrid y NTIC Máster.

Navas-Palencia, G. (2020). Optimal binning: mathematical programming formulation. arXiv:2001.08025.

Reglamento (UE) 575/2013, de 26 de junio de 2013, sobre los requisitos prudenciales de las entidades de crédito (CRR).

Siddiqi, N. (2017). *Intelligent Credit Scoring*. Wiley.

Valdrighi, G. et al. (2025). Best practices for responsible machine learning in credit scoring. *Neural Computing and Applications*, 37(25), 20781–20821.

Yeh, I. C. (2016). *Default of Credit Card Clients* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C55S3H

Yeh, I. C., & Lien, C. H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2), 2473-2480.

Anexos

El material complementario está disponible en https://github.com/PabloBlasHdez/TFM_Scoring_Comportamiento_Credito_PBH , y se organiza en las siguientes carpetas:

- Anexo 1 - Notebook de modelización (01_notebook): Desarrollo completo (EDA, tramificación WOE, scorecard, validación, XGBoost, SHAP, MLflow, optimización de hiperparámetros, variables derivadas, cálculo de ECL y exportaciones).
- Anexo 2 - Agentes conversacionales (02_chatbot): Aplicación Streamlit con LangChain, herramientas de scoring, prompt del sistema y alertas de recobro y script de precálculo de la cartera.
- Anexo 3 - Análisis de equidad (03_fairness): Disparate Impact, modelo proxy y justificación de la exclusión de la variable sexo.
- Anexo 4 - Base de datos (04_sql): Esquema relacional en SQLite y script de carga.
- Anexo 5 - API REST (05_api): Servicio FastAPI, Dockerfile y pruebas de los endpoints.
- Anexo 6 - Dataset (06_data): Fichero original "*Default of Credit Card Clients"* (UCI, CC BY 4.0) y fichero "config_riesgo".
- Anexo 7 - Dashboard (07_tableau): Datos exportados (xlsx) y enlace al dashboard en Tableau Public.
- Anexo 8 - Modelo de recobro (08_recobro): Notebook de construcción del conjunto, validación fuera de tiempo, estrategias y alertas de recobro.